

时间依赖型多时间窗车辆路径问题研究

李楠¹, 胡蓉^{1*}, 钱斌^{1,2}, 金怀平¹, 于乃康²

(1. 昆明理工大学 信息工程与自动化学院, 云南 昆明 650500; 2. 昆明理工大学 机电工程学院, 云南 昆明 650500)

摘要: 针对一类考虑城市交通拥堵情况的时间依赖型多时间窗车辆路径问题(time-dependent vehicle routing problem with multiple time windows, TD_VRPMTW), 提出一种混合离散灰狼算法(hybrid discrete grey wolf optimizer, HDGWO)进行求解。在HDGWO中, 设计了新的灰狼个体更新公式, 采用基于客户排列的整数编码方式, 使算法可直接在离散问题解空间中执行基于标准灰狼算法个体更新机理的全局搜索; 设计了基于问题性质的种群初始化策略, 用于生成具有高质量和多样性的初始种群; 引入头狼信息交流公式, 用于探索头狼形成的优质解空间; 构造具有多种局部搜索操作的自适应邻域局部搜索策略, 用于增强算法的局部搜索能力。结果表明: HDGWO可有效求解TD_VRPMTW。

关键词: 灰狼算法; 多时间窗; 车辆路径问题; 时间依赖; 离散; 局部搜索

中图分类号: TP391.9

文献标志码: A

文章编号: 1004-731X(2022)08-1775-14

DOI: 10.16182/j.issn1004731x.joss.21-0244

Research on Time-dependent Vehicle Routing Problem with Multiple Time Windows

Li Nan¹, Hu Rong^{1*}, Qian Bin^{1,2}, Jin Huaiping¹, Yu Naikang²

(1. School of Information Engineering and Automation, Kunming University of Science and Technology, Kunming 650500, China;

2. School of Mechanical and Electrical Engineering, Kunming University of Science and Technology, Kunming 650500, China)

Abstract: Aiming at the time-dependent vehicle routing problem with multiple time windows (TD_VRPMTW) that considers urban traffic congestion, a hybrid discrete gray wolf optimizer (HDGWO) is proposed. In the HDGWO, a new grey wolf individual updating formula is designed, and the integer coding method based on customer permutation is adopted, so that the algorithm can directly perform the global search based on GWO individual updating mechanism in the discrete problem solution space. A population initialization strategy based on the nature of the problem is designed to generate the initial population with high quality and diversity. The information exchange formula of the head wolf is introduced to explore the high-quality solution space formed by the head wolf. An adaptive variable neighborhood local search strategy with multiple local search operators is constructed to enhance the local search ability of the algorithm. Results show that HDGWO can effectively solve TD_VRPMTW.

Keywords: GWO; multiple time windows; vehicle routing problem; time-dependent; discrete; local search

收稿日期: 2021-03-23 修回日期: 2021-06-06

基金项目: 国家自然科学基金(61963022, 51665025)

第一作者: 李楠(1995-), 男, 硕士生, 研究方向为复杂系统智能优化。E-mail: 2235750519@qq.com

通讯作者: 胡蓉(1974-), 女, 博士, 副教授, 研究方向为智能优化调度、物流优化。E-mail: ronghu@vip.163.com

引言

多时间窗车辆路径问题(vehicle routing problem with multiple time windows, VRPMTW)广泛存在于工业气体分配^[1]、长途运输^[2]和团队定向^[3]等调度问题中。目前,关于VRPMTW的研究都是基于车辆行驶速度恒定的假设,忽略了实际路网中由于上下班高峰等原因造成的城市交通拥堵情况。另外,对于时间相关的车辆路径问题(vehicle routing problem, VRP),假设行驶速度恒定的最优解可能是次优的,甚至是不可行的^[4]。在上述背景下,对考虑城市交通拥堵情况的时间依赖型多时间窗车辆路径问题(time-dependent VRPMTW, TD_VRPMTW)进行研究是十分必要的。

VRPMTW由Favaretto等^[5]提出,并设计了一种基于蚁群系统的双蚁群算法进行求解。VRPMTW自提出以来,因其具有重要的应用价值和复杂的理论研究价值受到众多学者的关注和研究。譬如,Belhaiza等^[6]提出一种混合变邻域禁忌搜索算法用于求解以总持续时间最小化为优化目标的VRPMTW;Beheshti等^[7]提出一种协同进化的多目标量子遗传算法用于求解同时以旅行成本最小化和顾客满意度最大化为优化目标的多目标VRPMTW;Huggo等^[8]采用变邻域搜索算法求解以总行驶时间和车辆使用数量最小化为优化目标的VRPMTW;Belhaiza等^[9]针对VRPMTW设计了3种全局多启动策略的多起点数据驱动进化算法进行求解;Baradaran等^[10]针对具有多个硬优先时间窗的异构车队VRP,设计了一种二进制人工蜂群算法进行求解;Li等^[11]针对具有分割配送、比例服务时间和多时间窗的同步VRP,提出一种分支切割算法进行求解;Bogue等^[12]提出一种列生成算法和一种基于可变邻域搜索的后优化启发式算法,用于求解以成本最小化为优化目标的VRPMTW;Hoogeboom等^[13]针对出发时间不固定的VRPMTW,提出一种自适应变邻域搜索算法和一种精确多项式时间算法进行求解。

Malandraki等^[14]给出了旅行时间为阶跃函数的时间依赖型车辆路径问题(time-dependent VRP, TDVRP)的混合整数规划模型,由此揭开了对TDVRP研究的序幕。但是旅行时间为阶跃函数的TDVRP并不符合“先入先出”(first in first out, FIFO)的准则^[4]。Ichoua等^[4]在Malandraki等^[14]的研究基础上提出了满足FIFO准则的基于速度时间依赖函数的TDVRP,并设计了改进的并行禁忌搜索算法,对所提出的模型进行实验验证;Figliozzi等^[15]分析了城市区域的早晚交通高峰,设计了带时间窗的时间依赖型车辆路径问题(time-dependent vehicle routing problem with time windows, TDVRPTW)的Figliozzi测试集;穆东等^[16]提出一种并行模拟退火算法,通过在主从式并行模拟退火算法框架下使用4种邻域搜索,对以最小化车辆数为优化目标的TDVRPTW进行求解;Peng等^[17]提出一种基于分支和价格的精确求解算法,用于求解以利润最大化为优化目标的带时间窗的时间依赖型取送货车车辆路径问题;Thomas等^[18]针对以持续时间最小化为优化目标的TDVRPTW,提出一种能够减少移动评估时间的变邻域搜索算法进行求解;张景玲等^[19]针对时间依赖型同时取送货车车辆路径问题,设计了一种基于禁忌搜索的超启发式算法进行求解。根据以上文献的调研,目前尚无考虑城市交通拥堵情况的时间依赖型多时间窗车辆路径问题的建模及求解算法的相关研究。

灰狼算法(GWO)是Mirjalili等^[20]通过模拟狼群的社会等级及狩猎机制提出的一种基于群体智能的连续随机优化算法。GWO一经提出,便受到研究者的广泛关注。然而,GWO最初是为优化连续问题而设计,在求解连续优化问题^[21-23]上有着广泛的应用,但在车辆路径等离散组合优化问题上的应用相对较少。为将GWO用于求解离散组合优化问题,黄戈文等^[24]提出一种采用灰狼空间整数编码的自适应遗传灰狼算法,用于求解带容量约束的车辆路径问题;Abed等^[25]针对云计算环境中工作流的优化调度问题,设计了一种采用LOV

(largest order value)方法将灰狼算法产生的连续解转换为离散解的离散灰狼算法进行求解;顾九春等^[26]针对作业车间节能调度问题,设计了基于速度-工序的离散整数编码方式,并引入一种基于跟踪模式和搜寻模式的多目标离散灰狼算法进行求解。综上所述,现有文献采用GWO求解离散组合优化问题(尤其是VRP)的研究仍十分有限,另外,现有文献针对离散组合优化问题所提出的离散灰狼算法均对GWO原有机制过于保留,主要表现为采用某种转换规则的编码解码方式实现算法从连续空间搜索到离散空间搜索的映射,或者是采用了基于问题性质的整数编码,但在设计个体位置更新时,对算法的离散化不够彻底。以上存在的问题导致算法的全局搜索实际效率并不高。因此,根据GWO本身的特性和TD_VRPMTW的性质,设计一种高效的离散灰狼算法是非常有必要的。

本文建立了以最小化总配送成本为优化目标的TD_VRPMTW数学规划模型。考虑到TD_VRPMTW解空间的复杂性,常规的元启发式算法和精确算法难以进行有效求解,设计了一种混合离散灰狼算法(hybrid discrete grey wolf optimizer, HDGWO)对其进行求解。

1 问题描述及模型建立

1.1 问题描述

如图1所示,TD_VRPMTW可描述为:拥有若干车辆的配送中心负责给具有多个时间窗口的客户配送货物,客户的位置、需求量、服务时间均为已知。由于城市道路存在交通拥堵的情况,导致车辆在不同时间段的行驶速度不同。要求在满足约束的条件下,合理安排配送路线,使车辆的配送总成本最小化。约束条件:①各条配送路线上服务的客户需求量总和不超过车辆的最大装载量;②车辆只能在客户规定的若干不重叠的时间窗内进行服务;③每个客户有且只能被访问一次;④车辆的行驶速度要满足相应时段的时间依赖函数。




图1 TD_VRPMTW示意图
Fig. 1 TD_VRPMTW schematic diagram

1.2 符号定义

本文所涉及的数学符号及定义如下:

V_0 : 客户集 $V_0 = \{1, 2, \dots, n\}$;

V : 节点集 $V = \{0\} \cup V_0$, 0表示配送中心;

K : 车辆集 $K = \{1, 2, \dots, m\}$;

W_i : 客户*i*的时间窗口集 $W_i = \{1, 2, \dots, T_i\}$;

n : 总客户数;

m : 总车辆数;

L : 出发时间分段数;

T_i : 客户*i*的最大时间窗口数;

r^k : 配送方案需要的车辆总数;

Q : 车辆的最大载重;

Q_{k0} : 车辆*k*从配送中心出发时的载重;

q_i : 客户*i*的需求量;

$[e_i^p, l_i^p]$: 客户*i*的第*p*个时间窗;

$[e_0, l_0]$: 配送中心时间窗;

v_{ijl} : 时间段*l*内车辆从客户*i*到客户*j*的行驶速度;

t_{ijk} : 车辆*k*从客户*i*到客户*j*的总行驶时间;

d_{ijlk} : 时间段*l*内车辆*k*以速度 v_{ijl} 从客户*i*到客户*j*的行驶里程;

t_{ijlk} : 时间段*l*内车辆*k*以速度 v_{ijl} 从客户*i*到客

户 j 的行驶时间;

D_{ij} : 客户 i 到客户 j 的距离;

w_i^k : 车辆 k 在客户 i 处的等待时间;

a_i^k : 车辆 k 到达客户 i 的时间;

b_i^k : 车辆 k 离开客户 i 的时间;

s_i : 客户 i 处的服务时间;

c : 车辆发车固定成本;

c_1 : 车辆的单位行驶成本;

c_2 : 车辆提前到达的等待成本;

x_{ijk} : 决策变量, 若车辆 k 从客户 i 到客户 j 时为1, 否则为0;

y_{ik} : 决策变量, 若客户 i 由车辆 k 服务时为1, 否则为0;

z_{ik}^p : 决策变量, 若车辆 k 在客户 i 的第 p 个时间窗内为其服务时为1, 否则为0。

1.3 时间依赖型路网

本文采用 Ichoua 等^[4]提出的基于速度时间依赖函数的时间依赖型路网模型。如图2所示, 车辆的行驶速度为时间的分段函数, 每个时段拥有相同的行驶速度, 由此可得到同一路段(长度为1)下不同出发时间的行驶时间函数。




图2 车辆行驶速度和行驶时间的时问依赖函数

Fig. 2 Time-dependent function of vehicle speed and travel time

1.4 TD_VRPMTW 模型构建

目标函数式(1)表示最小化总配送成本, 包括所有车辆的发车成本、行驶成本和提前到达的等待成本:

$$\min Z = \sum_{k \in K} cr^k + \sum_{i \in V} \sum_{j \in V} \sum_{k \in K} c_1 D_{ij} x_{ijk} + \sum_{k \in K} \sum_{i \in V_0} c_2 w_i^k \quad (1)$$

客户点车辆流平衡约束, 即车辆到达客户 h

后必须离开:

$$\sum_{i \in V} x_{ihk} = \sum_{j \in V} x_{hjk}, \forall h \in V_0, \forall k \in K \quad (2)$$

相同节点之间没有路径连通:

$$x_{ijk} = 0, \forall i = j, \forall i, j \in V, \forall k \in K \quad (3)$$

每辆车仅有一条服务路径, 且服务完客户后必须返回配送中心:

$$\sum_{j \in V_0} x_{0jk} = \sum_{j \in V_0} x_{j0k} \leq 1, \forall k \in K \quad (4)$$

保证客户点被车辆服务时一定有路径与其连接:

$$\sum_{i \in V} x_{ijk} = y_{jk}, \forall j \in V_0, \forall k \in K \quad (5)$$

$$\sum_{j \in V} x_{ijk} = y_{ik}, \forall i \in V_0, \forall k \in K \quad (6)$$

车辆从配送中心出发时的载重约束:

$$Q_{k0} = \sum_{i \in V} \sum_{j \in V_0} q_j x_{ijk}, \forall k \in K \quad (7)$$

$$0 < Q_{k0} \leq Q, \forall k \in K \quad (8)$$

车辆从客户 i 到客户 j 在任意时段内行驶的距离约束:

$$d_{ijlk} \leq D_{ij} x_{ijk}, \forall i, j \in V, \forall l \in L, \forall k \in K \quad (9)$$

车辆从客户 i 到客户 j 在所有时段内行驶的距离约束:

$$\sum_{l \in L} \sum_{k \in K} d_{ijlk} = D_{ij} x_{ijk}, \forall i, j \in V \quad (10)$$

车辆在某个时段内行驶时间:

$$t_{ijlk} = d_{ijlk} / v_{ijl}, \forall i, j \in V, \forall l \in L, \forall k \in K \quad (11)$$

车辆从客户 i 到客户 j 的总行驶时间约束:

$$t_{ijk} = \sum_{l \in L} t_{ijlk} x_{ijk}, \forall i, j \in V, k \in K \quad (12)$$

车辆出发时间和返回时间约束:

$$b_{0k} = e_0, \forall k \in K \quad (13)$$

$$a_{0k} \leq l_0, \forall k \in K \quad (14)$$

车辆到达客户点的时间:

$$a_j^k = a_i^k + w_i^k + s_i + t_{ijk}, \forall i, j \in V, \forall k \in K \quad (15)$$

时间窗约束:

$$a_i^k + w_i^k \geq \sum_{p \in W_i} e_i^p z_{ik}^p, \forall i \in V, \forall k \in K \quad (16)$$

$$a_i^k + w_i^k \leq \sum_{p \in W_i} l_i^p z_{ik}^p, \forall i \in V, \forall k \in K \quad (17)$$

$$\sum_{p \in W_i} z_{ik}^p = 1, \forall i \in V, \forall k \in K \quad (18)$$

决策变量属性:

$$x_{ijk} \in \{0, 1\}, \forall i, j \in V, \forall k \in K \quad (19)$$

$$y_{jk} \in \{0, 1\}, \forall j \in V_0, \forall k \in K \quad (20)$$

$$z_{ik}^p \in \{0, 1\}, \forall i \in V, \forall k \in K \quad (21)$$

2 灰狼算法(GWO)

GWO中, 一个灰狼种群被分为 α 、 β 、 δ 和 ω 4个等级。其中, 狼群 ω 在头狼 α 、 β 、 δ 的带领下实现对猎物的寻找、包围和狩猎操作。GWO位置更新:

$$A = 2a \cdot r_1 - a \quad (22)$$

$$C = 2 \cdot r_2 \quad (23)$$

式中: A 和 C 为协同系数向量; a 为收敛因子, 在算法的迭代过程中从2线性递减为0; r_1 和 r_2 为 $[0, 1]$ 中的随机向量。

$$D_\alpha = |C_1 \cdot X_\alpha(\text{gen}) - X(\text{gen})| \quad (24)$$

$$D_\beta = |C_2 \cdot X_\beta(\text{gen}) - X(\text{gen})| \quad (25)$$

$$D_\delta = |C_3 \cdot X_\delta(\text{gen}) - X(\text{gen})| \quad (26)$$

式中: gen 为当前算法迭代次数; $X_\alpha(\text{gen})$ 、 $X_\beta(\text{gen})$ 和 $X_\delta(\text{gen})$ 分别为头狼 α 、 β 、 δ 的第 gen 代的位置向量; D_α 、 D_β 和 D_δ 分别为灰狼个体 $X(\text{gen})$ 与头狼 α 、 β 、 δ 的距离。

计算灰狼个体 $X(\text{gen})$ 下一步的位置:

$$X_1 = X_\alpha(\text{gen}) - A_1 \cdot D_\alpha \quad (27)$$

$$X_2 = X_\beta(\text{gen}) - A_2 \cdot D_\beta \quad (28)$$

$$X_3 = X_\delta(\text{gen}) - A_3 \cdot D_\delta \quad (29)$$

$$X(\text{gen} + 1) = (X_1 + X_2 + X_3)/3 \quad (30)$$

GWO的具体原理和步骤详见文献[20]。

3 混合离散灰狼算法

3.1 编码与解码

GWO是针对连续优化问题设计的, 在编码上采

用实数编码方式, 而本文研究的TD_VRPMTW属于离散优化问题, 因此, 不能直接采用GWO中的编码方式来对TD_VRPMTW进行编码。本文设计了基于客户排列的整数编/解码策略。编码时, 采用去除配送中心后的客户排列进行编码; 解码时, 根据车辆的载重、客户的时间窗, 以及行驶速度的约束, 采用先路由后分组的方式进行解码, 如图3所示。




图3 编码与解码

Fig. 3 Encoding and decoding

图3中, $X_i^{\text{gen}} = [X_i^{\text{gen}}[1], X_i^{\text{gen}}[2], \dots, X_i^{\text{gen}}[n]]$ 为第 gen 代个体 i 基于客户排列的位置向量; $R_i^{\text{gen}} = [R_i^{\text{gen}}[1], R_i^{\text{gen}}[2], \dots, R_i^{\text{gen}}[S]]$ 为对 X_i^{gen} 解码后得到的一个完整的配送方案; S 为 R_i^{gen} 的长度, $2 + n \leq S \leq 2n + 1$; $C_i^{\text{gen}} = [C_i^{\text{gen}}[1], C_i^{\text{gen}}[2], \dots, C_i^{\text{gen}}[C_i^{\text{gen}}[1] + 2]]$ 为与 X_i^{gen} 和 R_i^{gen} 相对应的具有存储功能的存储向量, C_i^{gen} 的第一个元素代表 R_i^{gen} 对应的配送方案所用车辆的数量, $C_i^{\text{gen}}[2] \sim C_i^{\text{gen}}[C_i^{\text{gen}}[1] + 1]$ 中的元素分别为每辆车的配送成本, 最后一个元素 $C_i^{\text{gen}}[C_i^{\text{gen}}[1] + 2]$ 表示该配送方案的总成本。在后期进行自适应变邻域局部搜索时, 只需对参与局部搜索的路径重新计算配送成本, 可以在很大程度上减少计算量。

3.2 种群初始化

优良的初始种群可以减小算法的搜索范围, 避免算法在劣质解上进行不必要的搜索。本文根据TD_VRPMTW的特点, 设计了车辆行驶路程最短和车辆等待时间最小2种初始化规则。

令 V_1 为未被服务的客户点集合, V_2 为 V_1 中满足当前约束的下一客户点集合。

(1) 车辆行驶路程最短规则如下:

step 1: 令 $i = 0, j = 0, V_1 = V_0, V_2 = \emptyset,$

$R_1^1 = \emptyset;$

step 2: 车辆从点 i 出发, $R_1^1[j] = i$, 将从点 i 到 V_1 中每一个满足约束条件的客户添加到 V_2 中;

step 3: 若 $V_2 = \emptyset$, 则车辆返回配送中心, $R_1^1[j+1] = 0$; 否则, 在 V_2 中选择距离最短的客户 b 作为下一个被服务的客户, $R_1^1[j+1] = b$, 并将该客户从 V_1 中去除。若集合 V_2 中有多个相同距离最短的客户, 则选取等待时间最小的客户 b' 作为下一个被服务的客户, $R_1^1[j+1] = b'$, 并将该客户从 V_1 中去除;

step 4: 若 $V_1 = \emptyset$, 则输出 R_1^1 ; 否则, 令 $V_2 = \emptyset$, $i = R_1^1[j+1]$, $j = j+1$, 转至 step 2。

(2) 车辆等待时间最小规则如下:

step 1: 令 $i = 0$, $j = 0$, $V_1 = V_0$, $V_2 = \emptyset$, $R_2^1 = \emptyset$;

step 2: 车辆从点 i 出发, $R_2^1[j] = i$, 将从点 i 到 V_1 中每一个满足约束条件的客户添加到 V_2 中;

step 3: 若 $V_2 = \emptyset$, 则车辆返回配送中心, $R_2^1[j+1] = 0$; 否则, 在 V_2 中选择等待时间最小的客户 b 作为下一个被服务的客户, $R_2^1[j+1] = b$, 并将该客户从 V_1 中去除。若集合 V_2 中有多个相同最小等待时间的客户, 则选取距离 i 最近的客户 b' 作为下一个被服务的客户, $R_2^1[j+1] = b'$, 并将该客户从 V_1 中去除;

step 4: 若 $V_1 = \emptyset$, 则输出 R_2^1 ; 否则, 令 $V_2 = \emptyset$, $i = R_2^1[j+1]$, $j = j+1$, 转至 step 2。

以上2种初始化规则只能产生2个初始解 R_1^1 和 R_2^1 , 通过对 R_1^1 和 R_2^1 执行2种扰动操作, 用于生成种群大小50%的初始解。2种扰动操作为: ①随机选择 R_1^1 或 R_2^1 中的2个非配送中心位置 u 、 v , 将 u 、 v 互换; ②随机选择 R_1^1 或 R_2^1 中的2个非配送中心位置 u 、 v , 将 u 插入到 v 前面。为保证初始种群的多样性和分散性, 剩余50%的初始解由随机规则产生。通过以上初始化策略, 可生成第一代种群 X_i^1 对应的解 R_i^1 , 将 R_i^1 中的配送中心去除后即可得到初始种群 X_i^1 。

3.3 头狼信息交流

在GWO中, 狼群 ω 在头狼 α 、 β 、 δ 的带领下

实现对猎物的寻找、包围和狩猎行为。但是作为狼群中最具优势信息的头狼之间却没有任何信息交流。因此, 为了充分利用头狼的优质信息, 提出了头狼信息交流公式, 以实现在头狼附近扩大搜索范围, 探索更为优质的解区域:

$$X_{\alpha\beta\delta}^{\text{new}} = [X_1^{\text{gen}}, X_2^{\text{gen}}]^T r^{[d,e]} \quad (31)$$

式中: $X_1^{\text{gen}}, X_2^{\text{gen}}$ 为第 gen 代头狼 α 、 β 、 δ 中的任意2只头狼; $[X_1^{\text{gen}}, X_2^{\text{gen}}]^T r^{[d,e]}$ 为对 X_1^{gen} 和 X_2^{gen} 执行基于 $r[d,e]$ 的交叉操作, $r[d,e]$ 表示随机生成的长度, 用于控制交叉的距离, 其中 $1 \leq d \leq e \leq n$ 。交叉操作采用如图4所示的顺序交叉法 (order crossover, OX)。本文对 α 、 β 、 δ 形成的6种组合排列按照式(31)进行6次头狼信息交流, 然后将得到的6个新的灰狼个体与种群中 popsize 个灰狼个体混合后, 按照适应度大小重新确定 α 、 β 、 δ 和 ω 。




图4 OX示意图

Fig. 4 Schematic diagram of OX

3.4 个体位置更新

由于GWO是为处理连续优化问题而设计的, 在编码上采用实数编码方式, 故可以通过四则运算规则对灰狼的实数位置进行处理, 但对于TD_VRPMTW这类典型的离散组合优化问题, 不能直接使用GWO中的个体更新公式。文献[24-26]等通过采用某种规则的编码, 在离散问题中实现了GWO中的个体更新行为, 但是, 由于问题的离散性, 这种方法会造成灰狼个体中优质信息的流失。因此, 本文设计了一种既考虑了TD_VRPMTW的

离散特点, 又实现了在 TD_VRPMTW 离散问题解空间中实现基于 GWO 个体更新机理的新的灰狼个体更新公式:

$$X_{\text{new}}^{\text{gen}} = [r_c \otimes [X_0^{\text{gen}}]^{r_m}, X^{\text{gen}}]^{a[d,e]} \quad (32)$$

式 (32) 依次执行的步骤分别为 $[X_0^{\text{gen}}]^{r_m}$, $r_c \otimes [X_0^{\text{gen}}]^{r_m}$ 和 $[r_c \otimes [X_0^{\text{gen}}]^{r_m}, X^{\text{gen}}]^{a[d,e]}$, 下面分别对 3 个步骤进行介绍。

(1) $[X_0^{\text{gen}}]^{r_m}$ 描述

标准 GWO 中, 灰狼个体的更新是分别计算出个体与 α 、 β 、 δ 的距离, 然后在 α 、 β 、 δ 周围随机更新。本文采用的方法是随机向 α 、 β 、 δ 中的一个进行靠近:

$$\bar{X}_0^{\text{gen}} = [X_0^{\text{gen}}]^{r_m} = \begin{cases} X_{\alpha}^{\text{gen}}, & r_m \geq 2/3 \\ X_{\beta}^{\text{gen}}, & 1/3 \leq r_m < 2/3 \\ X_{\delta}^{\text{gen}}, & r_m < 1/3 \end{cases} \quad (33)$$

式中: $[X_0^{\text{gen}}]^{r_m}$ 为以概率 r_m 对 α 、 β 、 δ 进行随机挑选。执行该操作后 $[X_0^{\text{gen}}]^{r_m}$ 变为 $\bar{X}_0^{\text{gen}}$ 。

(2) $r_c \otimes \bar{X}_0^{\text{gen}}$ 描述

GWO 中狼群 ω 在向头狼 α 、 β 、 δ 靠近时(如式 (24)~(26)所示), 使用随机数 C 控制狼群 ω 以随机的距离向头狼靠近, 避免算法陷入局部最优。本文设计了一种新的随机距离公式, 用来避免算法陷入局部最优:

$$\bar{X}_{0_new}^{\text{gen}} = r_c \otimes \bar{X}_0^{\text{gen}} = \begin{cases} \bar{X}_0^{\text{gen}}, & \text{if } \text{rand}[0, 1] < r_c \\ \bar{X}_0^{\text{gen}}, & \text{else} \end{cases} \quad (34)$$

$$\bar{X}_0^{\text{gen}} = \begin{cases} \text{Swap}(\bar{X}_0^{\text{gen}}, u, v) \\ \text{Insert}(\bar{X}_0^{\text{gen}}, u, v) \end{cases} \quad (35)$$

若产生的随机数小于 r_c , 则对选中的头狼 $\bar{X}_0^{\text{gen}}$ 以概率 r_c 执行式(35)所示的扰动操作, 将扰动后得到的 $\bar{X}_0^{\text{gen}}$ 作为狼群 ω 靠近的对象; 否则, 直接将选中的头狼 $\bar{X}_0^{\text{gen}}$ 作为狼群 ω 靠近的对象。式 (35)中的扰动操作为: 在 $\bar{X}_0^{\text{gen}}$ 中随机挑选 2 个位置 u 和 v , $\text{Swap}(\bar{X}_0^{\text{gen}}, u, v)$ 表示将 u 和 v 互换, $\text{Insert}(\bar{X}_0^{\text{gen}}, u, v)$ 表示将 u 插入到 v 前面。执行该

操作后, $r_c \otimes \bar{X}_0^{\text{gen}}$ 变为 $\bar{X}_{0_new}^{\text{gen}}$ 。

(3) $[\bar{X}_{0_new}^{\text{gen}}, X^{\text{gen}}]^{a[d,e]}$ 描述

该操作与 3.3 节中的交叉操作相同, 不同点在于 $a[d,e]$ 所控制的长度并不是随机的, 标准 GWO 使用收敛因子 a 用于实现 α 、 β 、 δ 带领狼群 ω 进行狩猎、包围和攻击的行为, 本文设计 $a[d,e]$ 用于模仿标准 GWO 的以上行为。 $a[d,e]$ 的取值为

$$a[d,e] = \left\lfloor (a[d,e]_{\max} - a[d,e]_{\min}) \cdot \frac{\text{gen}}{\text{gen}_{\max}} \right\rfloor \quad (36)$$

式中: $a[d,e]_{\max}$ 为灰狼个体位置的长度(即所有客户的数量); $\lfloor \cdot \rfloor$ 表示取整操作。确定 $a[d,e]$ 后, 对 ω 狼群中的个体 X^{gen} 以距离 $a[d,e]$ 向头狼 $\bar{X}_{0_new}^{\text{gen}}$ 靠近, 至此, HDGWO 的个体更新阶段结束。

3.5 自适应邻域局部搜索

对于组合优化问题, 由于问题的解空间庞大且复杂, 大量优质解往往分散在解空间中的多个局部区域, 故需要对算法搜索到的全局最优解进行较为细致的变邻域搜索。另外, 采用单一邻域操作的迭代搜索容易较早达到并陷入对应邻域结构的局部最优。因此, 本文根据 TD_VRPMTW 的性质设计了路径内和路径间基于交换、插入和逆序邻域的 10 种局部搜索操作。本文在算法的迭代过程中对局部搜索操作的挑选是根据各局部搜索操作的贡献率通过轮盘赌进行自适应选择。下面对自适应变邻域局部搜索进行介绍。

3.5.1 局部搜索操作

路径内的 5 种局部搜索操作为:

- (1) $\text{Swap_in_1}(R, u, v)$, 在 R 中随机挑选一条路径, 并随机挑选相邻的 2 个客户 u , v 互换;
- (2) $\text{Swap_in_2}(R, u, v)$, 在 R 中随机挑选一条路径, 并随机挑选不相邻的 2 个客户 u , v 互换;
- (3) $\text{Insert_in_1}(R, u, v)$, 在 R 中随机挑选一条路径, 并随机挑选 2 个客户 u , v , 将序列号大的客户 v 插入到序列号小的客户 u 的前面;

(4) $\text{Insert_in_2}(R, u, v)$, 在 R 中随机挑选一条路径, 并随机挑选 2 个客户 u, v , 将序列号小的客户 u 插入到序列号大的客户 v 的前面;

(5) $\text{Reverse_in}(R, u, v)$, 在 R 中随机挑选一条路径, 并随机挑选 2 个客户 u, v , 将客户 u, v 之间的客户逆序。

路径间的 5 种局部搜索操作为:

(1) $\text{Swap_out_1}(R, u, v)$, 在 R 中随机挑选 2 条路径, 在路径 1 中随机挑选一个客户 u , 在路径 2 中随机挑选一个客户 v , 将客户 u, v 互换;

(2) $\text{Swap_out_2}(R, u, v, u', v', l)$, 在 R 中随机挑选 2 条路径, 在路径 1 中随机挑选长度为 l ($l \in [2, 4]$) 的由 2 个客户 u, v 构成的连续客户序列, 在路径 2 中随机挑选长度为 l 的由 2 个客户 u', v' 构成的连续客户序列, 将客户 u, v 和 u', v' 之间的客户(包含客户 u, v 和 u', v')按原序列互换;

(3) $\text{Swap_out_3}(R, u, v, u', v', l)$, 在 R 中随机挑选 2 条路径, 在路径 1 中随机挑选长度为 l ($l \in [2, 4]$) 的由 2 个客户 u, v 构成的连续客户序列, 在路径 2 中随机挑选长度为 l 的由 2 个客户 u', v' 构成的连续客户序列, 将客户 u, v 和 u', v' 之间的客户(包含客户 u, v 和 u', v')逆序后互换;

(4) $\text{Swap_out_4}(R, u, v, u', v', l)$, 在 R 中随机挑选 2 条路径, 在路径 1 中随机挑选 l ($l \in [2, 4]$) 个客户 $u, \dots, v$, 在路径 2 中随机挑选 l 个客户 $u', \dots, v'$, 将 $u, \dots, v$ 和 $u', \dots, v'$ 对应的客户顺序交换;

(5) $\text{Insert_out}(R, u, v)$, 在 R 中随机挑选 2 条路径, 并随机挑选其中的一条作为被插入路径, 另一条作为插入路径, 在被插入路径中随机挑选一个客户 u , 在插入路径中随机挑选一个客户 v , 将客户 v 插入到客户 u 前面。

3.5.2 自适应动态选择局部搜索操作

在算法的进化过程中, 每次对局部搜索操作的动态选择过程如下:

令 Sp_i^{gen} 为局部搜索操作 i 在第 gen 代的贡献率, L_i^{gen} 为局部搜索操作 i 在第 gen 代的贡献值,

P^{gen} 为第 gen 代各局部搜索操作的累积概率矩阵。

step 1: 设置初始贡献值 $L_i^0 = 1$;

step 2: 计算每一次迭代中第 i 个局部搜索操作的贡献率:

$$Sp_i^{gen} = \frac{L_i^{gen}}{\sum L_i^{gen}}, i \in (1, 2, 3, 4, 5) \quad (37)$$

step 3: 根据每个局部搜索操作的贡献率计算每个局部搜索操作的累积概率:

$$P^{gen}[i] = \sum Sp_i^{gen}, i \in (1, 2, 3, 4, 5) \quad (38)$$

step 4: 采用轮盘赌策略对每一次的局部搜索操作进行选择, 若该次迭代中选中的局部搜索操作使得当前解的质量得到改善, 则 $L_i^{gen} = L_i^{gen} + 1$, 若当前解的质量未得到改善, 则 L_i^{gen} 不变;

step 5: 若 $gen \leq gen_max$, 则转至 step 2, 否则, 终止循环。

3.5.3 自适应邻域局部搜索步骤

对于路径内局部搜索, 本文对任意一条包含 2 个及以上客户的路径均进行自适应邻域局部搜索, 搜索次数 σ_1 为该路径中的客户数乘以系数 θ ; 对于路径间局部搜索, 按照该配送方案中所使用的车辆数 2 倍的次数任意挑选 2 个路径, 然后对选出的 2 条路径进行自适应邻域局部搜索, 搜索次数 σ_2 为 2 路径中服务最多的客户数乘以系数 λ 。自适应邻域局部搜索步骤如下:

step 1: 输入个体 R_i^{gen} , 令 $R_0 = R_i^{gen}$;

step 2: 扰动阶段;

step 2.1: 令 $loop_0=1$;

step 2.2: 随机选择 u 和 $v(u \neq v)$, $R_1 = \text{Swap_out_1}(R_0, u, v)$;

step 2.3: $R_0 = R_1$, 若 $loop_0 \leq 5$, 则转至 step 2.2。否则输出 R_1 , 转至 step 3;

step 3: 路径内开发阶段;

step 3.1: 令 $loop_1=1$;

step 3.2: 按照 3.5.2 节对路径内局部搜索操作进行自适应动态挑选;

step 3.3: 对 R_1 按照 step 3.2 选中的路径内局部搜索操作执行局部搜索, 新的个体记为 R_2 ;

step 3.4: 若 $f(R_2) < f(R_1)$, 则令 $R_1 = R_2$;

step 3.5: $loop_1 = loop_1 + 1$;

step 3.6: 若 $loop_1 \leq \sigma_1$, 则转至 step 3.2, 否则输出 R_1 并转至 step 4;

step 4: 路径间开发阶段;

step 4.1: 令 $loop_2 = 1$;

step 4.2: 按照 3.5.2 节 step 对路径间局部搜索操作进行自适应动态挑选;

step 4.3: 对 R_1 按照 step 4.2 选中的路径间局部搜索操作执行局部搜索, 新的个体记为 R_2 ;

step 4.4: 若 $f(R_2) < f(R_1)$, 则令 $R_1 = R_2$;

step 4.5: $loop_2 = loop_2 + 1$;

step 4.6: 若 $loop_2 \leq \sigma_2$, 则转到 step 4.2, 否则转至 step 5;

step 5: 若 $f(R_1) < f(R_i^{gen})$, 则令 $R_i^{gen} = R_1$ 。

3.6 HDGWO 流程

算法流程如图5所示。

令 $P(gen)$ 为算法第 gen 代种群, 种群大小为 $popsiz$, 算法的最大运行代数为 gen_max , 根据 3.1~3.5 节的描述, HDGWO 的具体步骤如下:

step 1: 设置算法参数, 令 $gen=1$, 并根据 3.2 节提出的初始化规则产生种群大小为 $popsiz$ 的初始种群;

step 2: 计算种群中所有个体的适应度值, 并按照适应度值的大小确定第一代的 α 、 β 、 δ 和 ω ;

step 3: 根据 3.3 节对 α 、 β 、 δ 进行头狼信息交流;

step 4: 根据 3.4 节, 将 ω 中的个体分别向 α 、 β 、 δ 狼靠近以更新群体 ω 位置, 并将种群位置更新后的解按照适应度由小到大的顺序对种群中的个体进行排序, 重新确定 α 、 β 、 δ 和 ω ;

step 5: 根据 3.5 节, 对 α 、 β 、 δ 按照先路径内、后路径间的顺序进行自适应变邻域局部搜索, 局部搜索后再按照适应度大小重新确定 α 、 β 、 δ ;

step 6: $gen = gen + 1$, 如果 $gen \leq gen_max$,

转到 step 2, 否则, 输出最优值。




图5 HDGWO 流程图

Fig. 5 Flow chart of HDGWO

4 算法验证及结果分析

对于 TD_VRPMTW, 目前还没有相应的基准算例。本文参考文献[15]的做法, 并将文献[15]设计的4组时间依赖函数引用到文献[6]的测试算例中, 构成 TD_VRPMTW 的测试算例。本文所有算法和测试程序均由 Python 3.7 编码实现, 操作系统为 Windows 10, CPU 主频为 3.30 GHz, 内存为 8 GB。每种算法独立重复运行 30 次, 终止条件为 $t > 60$ s。每次运行记录目标值 f 。

4.1 算法参数设置

参照文献[27], 本文将优化目标函数(见式(1))中的参数设置为: 单位发车成本 $c=300$ 元/辆, $c_1=1.5$ 元/km, $c_2=15$ 元/h。HDGWO 涉及到的关键参数有种群规模 $popsiz$ 、扰动概率 r_c 、路径内局部搜索系数 θ 、路径间局部搜索系数 λ 。本节针对时间依赖函数为 TD3a 下的一组具有中等时间窗规模的算例 rm203, 采用实验设计方法 (design of

experiment, DOE)^[28], 对关键参数的取值进行实验分析。进而确定 HDGWO 的最佳关键参数组合为: $popsiz=25$ 、 $r_c=0.6$ 、 $\theta=3$ 、 $\lambda=3$ 。

4.2 HDGWO 关键环节有效性验证

HDGWO 的关键环节包括离散化的全局搜索机制、种群初始化规则和自适应邻域局部搜索策略。为验证各关键环节的有效性, 本文将 HDGWO 与文献[24-25]只保留编解码方式和个体更新机制的变形算法 GWO_V1、GWO_V2, 以及 HDGWO 的 2 种变形算法 HDGWO_V1、HDGWO_V2 进行对比, 具体如下:

- (1) GWO_V1: 采用灰狼空间整数编码, 并基于离散灰狼空间位置重新定义灰狼个体更新公式;
- (2) GWO_V2: 采用 LOV 规则将灰狼算法产生的连续解转换为离散解, 仍采用标准 GWO 中的个体更新公式;
- (3) HDGWO_V1: 将 HDGWO 中的种群初始

化规则和自适应邻域局部搜索策略移除, 只保留离散化的全局搜索机制, 初始种群由随机规则产生;

(4) HDGWO_V2: 将 HDGWO 中的自适应邻域局部搜索策略移除, 只保留离散化的全局搜索机制和种群初始化规则。

测试算例为时间依赖函数 TD3a 下的 TD_VRPMTW 算例。为保证算法对比的公平性, 所有对比算法参数设置均相同。实验结果如表 1 所示。由表 1 可知, HDGWO_V1 解的质量明显优于 GWO_V1 和 GWO_V2, 表明本文所提离散化的全局搜索机制使算法的全局搜索能力明显增强。HDGWO_V2 解的质量明显优于 HDGWO_V1, 表明本文所提的种群初始化策略可以有效提高初始种群的质量并引导算法的全局搜索快速发现解空间中的优质解区域。HDGWO 解的质量明显优于 HDGWO_V2, 表明本文所提自适应邻域局部搜索策略可以加深算法的搜索深度, 搜索到更好的解。

表 1 HDGWO 与多种变形算法的对比
Table 1 Comparison results of HDGWO and various deformation algorithms

算例	GWO_V1		GWO_V2		HDGWO_V1		HDGWO_V2		HDGWO	
	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG
rm101	8 752.0	9 086.1	8 029.8	9 065.6	7 435.0	7 933.7	5 357.6	5 569.1	4 453.5	4 529.6
rm103	9 540.1	9 798.1	9 174.0	9 933.7	8 050.3	8 602.0	6 199.8	6 439.5	4 912.0	5 223.7
rm105	10 439.7	10 873.0	9 338.5	10 120.5	8 845.3	9 335.4	6 071.8	6 347.8	5 492.5	5 737.2
rm201	10 613.1	11 359.9	10 427.9	11 762.4	8 259.7	8 880.0	5 277.4	5 386.1	5 144.5	5 276.0
rm203	16 425.3	17 672.8	14 695.5	16 913.6	11 418.2	12 858.4	7 008.8	7 173.6	6 369.0	6 581.9
rm205	22 648.9	25 069.1	18 614.1	21 045.3	14 166.5	17 606.6	9 000.5	9 234.5	6 917.7	7 140.3
cm101	6 641.8	7 220.9	7 313.1	8 205.3	6 410.7	6 755.8	5 518.3	5 702.3	4 736.3	5 077.0
cm103	7 571.5	8 026.2	7 820.8	8 239.4	6 924.7	7 337.6	5 859.9	5 989.7	5 467.0	5 691.3
cm105	8 179.0	8 585.2	8 227.1	8 787.2	7 476.0	7 687.0	6 443.4	6 718.6	5 337.7	5 721.0
cm201	9 043.6	9 961.2	8 531.9	9 694.1	7 178.0	8 156.2	5 557.9	5 803.4	4 987.9	5 216.1
cm203	11 233.9	12 269.9	10 844.7	12 137.4	9 145.2	10 028.0	6 176.8	6 322.5	5 499.5	5 856.1
cm205	12 518.8	13 821.2	11 267.4	13 259.4	9 985.5	10 863.7	6 312.4	6 987.9	5 656.0	5 971.8
rcm101	11 107.8	11 616.8	10 449.5	11 397.3	8 981.9	10 108.2	7 473.5	7 807.7	5 468.9	5 782.7
rcm103	11 420.4	12 010.1	10 867.9	11 867.7	9 711.1	10 458.8	7 450.3	7 604.8	5 774.8	6 024.5
rcm105	11 620.9	12 470.3	11 223.9	12 049.4	10 213.8	10 811.9	7 906.0	8 180.7	5 428.3	5 984.5
rcm201	13 400.6	13 763.6	12 080.1	14 124.6	9 825.9	10 914.8	5 399.0	5 906.9	5 238.4	5 799.6
rcm203	17 727.4	18 722.6	16 887.3	18 826.4	12 809.9	14 301.9	7 383.0	7 642.0	6 771.0	6 994.2
rcm205	17 036.2	18 507.4	15 402.5	17 651.3	11 831.9	13 416.0	7 259.9	7 487.3	6 442.8	6 591.7

通过对 HDGWO 与各变形算法的对比分析, 验证了 HDGWO 中的各关键环节的有效性。

4.3 HDGWO 与其他算法对比

为进一步验证 HDGWO 的有效性, 将 HDGWO 与国外重要期刊中求解 VRPMTW 的有效算法 HAVNTS^[6]和 AVNS^[13]分别在时间依赖函数为 TD3a、TD3b、TD3c 和 TD3d 的 4 组 TD_VRPMTW 测试算例上进行比较, 所有测试算例均在相同时间下进行 30 次独立实验, 各算法在不同时间依赖函数下的求解结果如表 2~3 所示。

由表 2~3 可知, HDGWO 在绝大部分问题上的测试结果都明显优于另外 2 种对比算法, 但是, 表 2~3 中 HDGWO 求解 CM1、CM2 在客户的分布上具有群集性测试算例的结果不如 HDGWO 在其他测试算例上相对于 AVNS 的优势明显。但在最优值和平均值上, HDGWO 仍有 50% 和 54.2% 的占优率。另外, 在不同的时间依赖函数下, HDGWO 的占优情况略有不同, 表明不同的时间依赖函数对算法的性能有着一定的影响。

综上可知, 本文所提的 HDGWO 能够有效求解 TD_VRPMTW。

表 2 HAVNTS、AVNS 和 HDGWO 在时间依赖函数 TD3a 和 TD3b 下的实验对比结果

Table 2 Experimental comparison results of HAVNTS, AVNS and HDGWO under time dependent functions TD3a and TD3b

算例	TD3a						TD3b					
	HAVNTS		AVNS		HDGWO		HAVNTS		AVNS		HDGWO	
	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG
rm101	5 063.5	5 479.8	4 890.2	5 187.2	4 713.4	4 952.0	4 904.3	5 513.1	4 535.7	4 939.3	4 439.0	4 572.1
rm103	5 616.2	5 804.5	4 983.8	5 475.2	5 035.0	5 367.6	5 595.1	5 969.4	5 106.6	5 428.3	4 855.9	5 300.8
rm105	5 716.4	5 999.8	5 403.4	5 885.0	5 502.9	5 690.3	6 123.3	6 455.7	5 470.4	6 017.7	5 541.2	5 930.9
rm201	7 189.5	7 371.9	6 024.2	7 054.0	4 862.6	5 091.2	7 581.0	7 893.3	6 395.5	7 439.5	5 236.5	5 305.1
rm203	7 541.9	8 067.7	7 306.9	7 719.3	5 219.5	6 430.3	7 851.8	8 496.3	7 443.4	7 876.1	6 507.9	6 654.3
rm205	8 272.7	9 560.2	9 072.1	9 393.7	8 031.8	8 346.6	8 184.6	9 161.8	8 016.9	9 066.1	7 055.8	7 267.8
cm101	5 059.9	5 276.8	4 947.6	5 093.3	4 887.6	5 119.5	5 237.1	5 513.8	4 881.2	5 099.2	4 810.5	5 157.4
cm103	5 434.7	5 702.4	5 241.8	5 458.3	5 159.7	5 414.5	5 893.3	6 149.7	5 630.9	5 873.2	5 520.5	5 687.7
cm105	5 547.7	5 739.8	5 273.8	5 563.5	5 383.5	5 560.1	5 933.8	6 197.8	5 339.7	5 752.7	5 458.2	5 645.5
cm201	4 778.8	5 032.9	4 379.5	4 647.0	4 718.7	4 937.1	5 447.8	5 694.8	4 920.3	5 245.1	5 133.6	5 336.6
cm203	5 063.6	5 505.1	4 714.5	5 209.0	4 966.1	5 111.9	5 715.1	6 367.3	5 282.6	5 754.8	5 716.9	5 954.6
cm205	5 228.5	5 686.5	4 907.6	5 337.1	5 051.9	5 665.2	5 819.4	6 259.7	5 332.1	5 818.4	5 776.4	6 067.1
rcm101	6 078.8	6 505.6	5 982.3	6 422.0	5 788.2	6 209.8	6 193.9	6 504.5	5 675.2	6 046.6	5 378.6	5 752.3
rcm103	6 014.7	6 566.7	6 007.0	6 597.4	5 820.4	6 225.9	6 207.4	6 702.6	5 856.1	6 320.4	5 830.2	6 106.2
rcm105	6 358.1	6 876.3	6 387.4	6 806.1	6 163.5	6 483.5	5 857.2	6 633.7	5 784.1	6 306.6	5 762.6	6 078.1
rcm201	7 288.1	8 641.2	7 177.7	8 199.1	4 869.9	5 099.9	8 078.6	9 401.7	7 683.4	8 629.0	5 375.2	5 673.9
rcm203	8 669.9	9 340.7	8 395.6	9 214.8	6 497.2	6 799.4	9 110.5	9 713.5	7 549.7	9 205.5	6 922.2	7 071.0
rcm205	8 887.1	9 586.2	8 576.6	9 018.9	6 400.6	6 736.9	8 916.2	9 579.6	7 501.8	8 938.1	6 496.8	6 676.1

表 3 HAVNTS、AVNS 和 HDGWO 在时间依赖函数 TD3c 和 TD3d 下的实验对比结果

Table 3 Experimental comparison results of HAVNTS, AVNS and HDGWO under time dependent functions TD3c and TD3d

算例	TD3c						TD3d					
	HAVNTS		AVNS		HDGWO		HAVNTS		AVNS		HDGWO	
	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG
rm101	5 302.8	5 552.0	5 130.8	5 354.9	4 540.7	4 767.5	4 884.3	5 318.2	4 476.1	5 007.6	4 521.8	4 759.4
rm103	5 435.8	6 011.0	5 300.6	5 756.8	4 944.7	5 256.1	5 257.1	5 887.5	5 157.0	5 534.0	4 879.9	5 241.4

续表

算例	TD3c						TD3d					
	HAVNTS		AVNS		HDGWO		HAVNTS		AVNS		HDGWO	
	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG	BST	AVG
rm105	5 625.6	5 995.9	5 259.2	5 820.4	5 375.0	5 572.0	6 000.7	6 314.2	5 676.5	6 120.0	5 636.7	5 909.4
rm201	6 056.5	7 112.1	6 563.6	6 752.9	4 741.5	4 945.6	6 446.5	7 618.0	6 248.2	7 248.2	4 059.9	5 095.6
rm203	7 034.6	7 487.4	6 887.3	7 266.0	6 099.4	6 314.3	7 841.5	8 482.7	7 797.0	8 401.4	5 735.7	6 687.2
rm205	7 786.6	8 740.1	7 645.2	8 452.4	6 925.0	7 787.7	9 544.9	10 149.9	8 327.3	9 615.0	8 349.7	9 136.3
cm101	4 549.1	4 739.3	4 403.9	4 566.7	4 381.1	4 600.5	5 737.2	5 993.5	5 531.4	5 835.3	5 449.4	5 790.3
cm103	5 336.0	5 521.1	5 158.1	5 402.9	5 090.4	5 358.4	5 941.0	6 192.0	5 781.9	6 039.7	5 706.3	5 872.2
cm105	5 176.8	5 355.6	5 012.4	5 160.6	5 001.7	5 186.0	6 202.2	6 412.2	5 997.4	6 280.9	5 929.2	6 196.2
cm201	4 343.6	4 530.1	4 184.1	4 307.0	4 287.1	4 507.2	6 048.1	6 974.5	5 481.4	6 543.3	5 432.9	5 642.3
cm203	4 849.2	5 038.3	4 568.5	4 808.2	4 670.1	4 825.2	7 060.4	7 469.0	6 924.4	7 203.8	6 283.7	7 129.0
cm205	4 726.3	5 043.1	4 703.0	4 847.0	4 740.3	4 825.9	6 465.7	7 534.3	6 134.6	7 411.1	6 364.6	7 398.3
rcm101	6 226.8	6 552.2	5 948.1	6 407.6	5 688.1	6 094.1	6 014.0	6 511.0	6 014.3	6 357.5	5 688.2	6 018.0
rcm103	6 320.6	6 793.5	6 161.1	6 617.0	5 843.5	6 078.4	6 403.9	6 601.8	6 070.7	6 608.0	6 014.9	6 187.0
rcm105	6 489.1	6 939.3	6 485.7	6 851.5	6 287.4	6 518.2	6 051.7	6 537.8	6 029.9	6 427.2	6 049.5	6 327.9
rcm201	7 357.8	8 425.3	6 899.9	8 176.6	5 005.0	5 141.2	7 879.1	9 253.9	7 684.7	8 859.0	5 314.5	6 263.9
rcm203	8 207.1	9 098.1	7 914.7	8 433.2	6 310.0	6 458.3	8 235.5	9 823.0	9 042.6	9 548.2	7 044.3	7 164.2
rcm205	8 192.1	8 558.9	6 845.0	8 190.9	6 177.4	6 332.5	9 120.1	9 779.9	6 594.1	9 001.6	5 371.0	6 526.8

5 结论

本文在多时间窗车辆路径问题的基础上，进一步考虑了实际配送中普遍存在的交通拥堵情况，对 TD_VRPMTW 进行研究，并提出一种 HDGWO 进行求解。主要贡献如下：

(1) 建立了以最小化总配送成本为优化目标的 TD_VRPMTW 的数学规划模型。

(2) 对 GWO 的离散化。根据 TD_VRPMTW 的特点，设计了一种基于客户排列的离散整数编码方式；引入了头狼信息交流公式，用于探索算法在迭代过程中头狼形成的优质解空间；对标准 GWO 中的个体更新公式进行离散化，使算法能够直接在 TD_VRPMTW 的离散解空间中执行基于标准 GWO 个体更新机理的全局搜索。

(3) 对 GWO 的改进。为克服 GWO 局部搜索能力的不足，设计了基于路径内和路径间具有多种局部搜索操作的自适应变邻域局部搜索策略，用于对全局搜索到的优质解空间进行更为细致的搜索。

仿真实验和算法比较验证了 HDGWO 是求解 TD_VRPMTW 的有效算法。后续研究将进一步考虑客户需求模糊下的时间依赖型多时间窗车辆路径问题，并设计高效的智能优化算法进行求解。

参考文献：

- [1] Bell W J, Dalberto L M, Fisher M L, et al. Improving the Distribution of Industrial Gases with an On-Line Computerized Routing and Scheduling Optimizer[J]. Interfaces (S0092-2102), 1983, 13(6): 4-23.
- [2] Rancourt M E, Cordeau J F, Laporte G. Long-haul Vehicle Routing and Scheduling with Working Hour Rules[J]. Transportation Science (S0041-1655), 2013, 47(1): 81-107.
- [3] Souffriau W, Vansteenwegen P, Berghe G V, et al. The Multiconstraint Team Orienteering Problem with Multiple Time Windows[J]. Transportation Science (S0041-1655), 2013, 47(1): 53-63.
- [4] Soumia Ichoua, Michel Gendreau, Jean Yves Potvin. Vehicle Dispatching with Time-Dependent Travel Times[J]. European Journal of Operational Research (S0377-2217), 2003, 144(2): 379-396.
- [5] Favaretto D, Moretti E, Pellegrini P. Ant Colony System for a VRP with Multiple Time Windows and Multiple Visits[J]. Journal of Interdisciplinary Mathematics

- (S0972-0502), 2007, 10(2): 263-284.
- [6] Slim Belhaiza, Pierre Hansen, Gilbert Laporte. A Hybrid Variable Neighborhood Tabu Search Heuristic for the Vehicle Routing Problem with Multiple Time Windows [J]. *Computers & Operations Research* (S0305-0548), 2014, 52: 269-281.
- [7] Beheshti A K, Hejazi S R, Alinaghian M. The Vehicle Routing Problem with Multiple Prioritized Time Windows: a Case Study[J]. *Computers & Industrial Engineering* (S0360-8352), 2015, 90: 402-413.
- [8] Hugo Silva Ferreira, Eduardo Theodoro Bogue, Thiago F Noronha, et al. Variable Neighborhood Search for Vehicle Routing Problem with Multiple Time Windows[J]. *Electronic Notes in Discrete Mathematics* (S1571-0653), 2018, 66: 207-214.
- [9] Slim Belhaiza, Rym M'Hallah, Ghassen Ben Brahim, et al. Three Multi-Start Data-Driven Evolutionary Heuristics for the Vehicle Routing Problem with Multiple Time Windows [J]. *Journal of Heuristics* (S1381-1231), 2019, 25(3): 485-515.
- [10] Vahid Baradaran, Amir Shafaei, Amir Hossein Hosseini. Stochastic Vehicle Routing Problem with Heterogeneous Vehicles and Multiple Prioritized Time Windows: Mathematical Modeling and Solution Approach[J]. *Computers & Industrial Engineering* (S0360-8352), 2019, 131: 187-199.
- [11] Li Jiliu, Qin Hu, Baldacci Roberto, et al. Branch-and-Price-and-Cut for the Synchronized Vehicle Routing Problem with Split Delivery, Proportional Service Time and Multiple Time Windows[J]. *Transportation Research Part E* (S1366-5545), 2020, 140: 101955.
- [12] Bogue E T, Ferreira H S, Noronha T F, et al. A Column Generation and a Post Optimization VNS Heuristic for the Vehicle Routing Problem with Multiple Time Windows[J]. *Optimization Letters* (S1862-4472), 2022, 16(6): 79-95.
- [13] Hoogeboom M, Dullaert W, Lai D, et al. Efficient Neighborhood Evaluations for the Vehicle Routing Problem with Multiple Time Windows[J]. *Transportation Science* (S0041-1655), 2020, 54(2): 400-416.
- [14] Chryssi Malandraki, Mark S Daskin. Time Dependent Vehicle Routing Problems: Formulations, Properties and Heuristic Algorithms[J]. *Transportation Science* (S0041-1655), 1992, 26(3): 185-200.
- [15] Miguel Andres Figliozzi. The Time Dependent Vehicle Routing Problem with Time Windows: Benchmark Problems, an Efficient Solution Algorithm, and Solution Characteristics[J]. *Transportation Research Part E* (S1366-5545), 2012, 48(3): 616-636.
- [16] 穆东, 王超, 王胜春, 等. 基于并行模拟退火算法求解时间依赖型车辆路径问题[J]. *计算机集成制造系统*, 2015, 21(6): 1626-1636.
- Mu Dong, Wang Chao, Wang Shengchun, et al. Solving Time Dependent Vehicle Routing Problem Based on Parallel Simulated Annealing Algorithm [J]. *Computer Integrated Manufacturing System*, 2015, 21(6): 1626-1636.
- [17] Sun Peng, Veelenturf Lucas P, Hewitt Mike, et al. The Time-Dependent Pickup and Delivery Problem with Time Windows[J]. *Transportation Research Part B* (S0191-2615), 2018, 116: 1-24.
- [18] Thomas R Visser, Remy Spliet. Efficient Move Evaluations for Time-Dependent Vehicle Routing Problems[J]. *Transportation Science* (S0041-1655), 2020, 54(4): 1091-1112.
- [19] 张景玲, 刘金龙, 赵燕伟, 等. 时间依赖型同时取送货VRP及超启发式算法[J]. *计算机集成制造系统*, 2020, 26(7): 1905-1917.
- Zhang Jingling, Liu Jinlong, Zhao Yanwei, et al. Time Dependent Simultaneous Delivery VRP and Super Heuristic Algorithm [J]. *Computer Integrated Manufacturing System*, 2020, 26(7): 1905-1917.
- [20] Mirjalili S, Mirjalili S M, Lewis A. Grey Wolf Optimizer [J]. *Advances in Engineering Software* (S0965-9978), 2014, 69(3): 46-61.
- [21] Ebenezer Daniel, J Anitha, J Gnanaraj. Optimum Laplacian Wavelet Mask Based Medical Image Using Hybrid Cuckoo Search-Grey Wolf Optimization Algorithm[J]. *Knowledge-Based Systems* (S0950-7051), 2017, 131: 58-69.
- [22] Pritam Keshavdas Gujarathi, Varsha A Shah, Makarand M Lokhande. Grey Wolf Algorithm for Multidimensional Engine Optimization of Converted Plug-In Hybrid Electric Vehicle[J]. *Transportation Research Part D* (S1361-9209), 2018, 63: 632-648.
- [23] Hemeida A M, Alkhalaf S, Mady A, et al. Implementation of Nature-Inspired Optimization Algorithms in Some Data Mining Tasks[J]. *Ain Shams Engineering Journal* (S2090-4479), 2020, 11(2): 309-318.
- [24] 黄戈文, 蔡延光, 戚远航, 等. 自适应遗传灰狼优化算法求解带容量约束的车辆路径问题[J]. *电子学报*, 2019, 47(12): 2602-2610.
- Huang Gewen, Cai Yanguang, Qi Yuanhang, et al. Adaptive Genetic Gray Wolf Optimization Algorithm for Vehicle Routing Problem with Capacity Constraint [J]. *Acta electronica Sinica*, 2019, 47(12): 2602-2610.
- [25] Abed alguni B H, Alawad N A. Distributed Grey Wolf Optimizer for Scheduling of Workflow Applications in

- Cloud Environments[J]. Applied Soft Computing (S1568-4946), 2021(102): 107113.
- [26] 顾九春, 姜天华, 朱惠琦. 多目标离散灰狼优化算法求解作业车间节能调度问题[J/OL]. 计算机集成制造系统: 1-18[2021-03-11]. <http://kns.cnki.net/kcms/detail/11.5946.TP.20200113.1129.018.html>.
- Gu Jiuchun, Jiang Tianhua, Zhu Huiqi. Multi Objective Discrete Grey Wolf Optimization Algorithm for Job Shop Energy Saving Scheduling Problem[J/OL]. Computer Integrated Manufacturing System: 1-18 [2021-03-11] <http://kns.cnki.net/kcms/detail/11.5946.TP.20200113.1129.018.html>.
- [27] 胡蓉, 李洋, 钱斌, 等. 结合聚类分解的增强蚁群算法求解复杂绿色车辆路径问题[J/OL]. 自动化学报. [2021-03-13]. <https://doi.org/10.16383/j.aas.c190872>.
- Hu Rong, Li Yang, Qian Bin, et al. Solving Complex Green Vehicle Routing Problem with Enhanced Ant Colony Algorithm Based on Clustering Decomposition [J/OL]. Journal of Automation. [2021-03-13] <https://doi.org/10.16383/j.aas.c190872>.
- [28] Montgomery D C. Design and Analysis of Experiments [M]. Hoboken: John Wiley and Sons, 2005.